

Guía G5 — Ventanas y Estimación Espectral

Análisis y Procesamiento de Señales — UNSAM

Antes de arrancar

Esta guía cierra todo lo que vimos sobre análisis espectral en señales finitas: ventanas, periodograma, Bartlett, Welch. Los ejercicios alternan preguntas conceptuales con práctica numérica. Las referencias al Holton son al capítulo 14.

Ejercicio 1: ¿Cuándo aparece desparramo espectral?

- a) El desparramo espectral aparece en *dos* situaciones distintas al calcular la DFT de un bloque finito de señal. Indique cuáles son las dos situaciones.
- b) Mire la Figura 14.6 del Holton (las cuatro ventanas: rectangular, Hamming, Hann y Blackman). ¿Qué dos parámetros de la ventana se ven en esa figura? ¿Cuál de ellos está relacionado con cada una de las dos situaciones del punto a)?
- c) Para $x[n] = \cos(2\pi \cdot 205 \cdot n/f_s)$ con $f_s = 1000$ Hz y $N = 100$ muestras, calcule:
- El espaciado de bins $\Delta f = f_s/N$.
 - El bin teórico al que corresponde 205 Hz ($k = f_0 \cdot N/f_s$).
 - ¿Cae justo en un bin entero?

Corra el código del final del ejercicio y mire el espectro: ¿dónde aparece energía además del pico?

Listing 1: Visualización rápida del desparramo

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import scipy.signal.windows as spsw
4
5 fs = 1000
6 N = 100
7 n = np.arange(N)
8 x = np.cos(2*np.pi * 205 * n / fs)
9
10 freqs = np.fft.rfftfreq(N, d=1/fs)
11
12 # Sin ventana (rectangular) vs Hann
13 for nombre, w in [("Rectangular", np.ones(N)),
14                  ("Hann", spsw.hann(N, sym=False))]:
15     X = np.fft.rfft(x * w) / N
16     plt.figure(figsize=(8, 3))
17     plt.plot(freqs, 20*np.log10(np.abs(X) + 1e-12), label=nombre)
18     plt.axvline(205, color="red", linestyle="--", label="205 Hz real")
19     plt.xlabel("Frecuencia [Hz]")
20     plt.ylabel("|X(f)| [dB]")
```

```

21 plt.title(f"Espectro con ventana {nombre}")
22 plt.ylim(-80, 0)
23 plt.grid(True); plt.legend(); plt.tight_layout()
24 plt.show()

```

Ejercicio 2: Tabla de ventanas

La siguiente tabla (Holton, Sec. 14.1.2) resume las ventanas más usadas:

Ventana	Ancho lób. ppal.	1 ^{er} lób. lat.	Para qué sirve
Rectangular	$4\pi/N$	-13 dB	máxima resolución
Hann	$8\pi/N$	-32 dB	uso general
Hamming	$8\pi/N$	-43 dB	señales débiles cercanas
Blackman-Harris	$12\pi/N$	-92 dB	señales muy débiles
Flatop	$\approx 18\pi/N$	-93 dB	medición de amplitud

Definiciones que vamos a usar:

- **Ancho del lóbulo principal:** ancho en frecuencia del pico central de la ventana. Más estrecho = mejor resolución.
- **Nivel del primer lóbulo lateral** (en dB): qué tan abajo está el primer “bulto” a los costados del pico, medido respecto a la cima del pico (que está en 0 dB). Cuanto más negativo, mejor.
- **Tapar una señal débil:** cuando tengo dos señales de distinta amplitud en frecuencias distintas, los lóbulos laterales de la señal fuerte pueden ser más altos que el pico de la señal débil, haciendo imposible verla en el espectro. Es como querer ver una vela al lado de un reflector.

a) Para $f_s = 8000$ Hz y $N = 800$, calcule la resolución mínima en Hz para cada ventana. Use:

$$\Delta f_{\min} = \frac{\Delta\omega}{2\pi} \cdot f_s$$

¿Cuál de las ventanas permite separar dos tonos a 50 Hz de distancia?

b) Tengo una señal con un pico fuerte en 0 dB y un pico débil en -40 dB en otra frecuencia. Para cada ventana de la tabla, decida si los lóbulos laterales del pico fuerte *tapan* al pico débil. (Use directamente la columna del primer lóbulo lateral).

c) La ventana **Flatop** tiene el lóbulo principal más ancho de todas, lo cual debería ser malo. Sin embargo se usa mucho en metrología. ¿Por qué? ¿Qué propiedad de su lóbulo principal la hace especial?

Ejercicio 3: Sesgo y varianza

a) Defina con sus propias palabras:

- ¿Qué es el *sesgo* de un estimador?
- ¿Qué es la *varianza* de un estimador?
- ¿Qué quiere decir que un estimador sea *consistente*?

b) En la TS4 se estudia el estimador de amplitud $\hat{a}_1 = |X_w^i(\Omega_0)|$ donde la frecuencia real Ω_1 tiene un pequeño desvío aleatorio respecto a Ω_0 .

Para cada propiedad pedida, indique qué ventana convendría usar y por qué:

Quiero estimar...	Conviene la ventana...
Amplitud con poco sesgo	_____
Frecuencia con poca varianza	_____

c) ¿Existe una ventana que sea óptima para ambas cosas? ¿Por qué sí o por qué no?

Ejercicio 4: Tipo parcial — Elección de ventana, N y f_s

Se tiene una señal compuesta por:

- Una senoidal de 0 dB en $f_1 = 1000$ Hz.
- Una cosenoidal de -40 dB en $f_2 = 1050$ Hz.
- Ruido gaussiano de fondo de -60 dB.

Quiero ver ambas señales separadas en el espectro.

Complete la siguiente tabla decidiendo, para cada ventana, si sirve o no para resolver el problema. Justifique brevemente.

Ventana	$N_{\min}$ p/ resolver	¿Detecta -40 dB?	¿Sirve?
Rectangular	_____	_____	_____
Hann	_____	_____	_____
Hamming	_____	_____	_____
Blackman-Harris	_____	_____	_____
Flatop	_____	_____	_____

Use $f_s = 8000$ Hz. La condición de resolución es $\Delta f_{\min} < 50$ Hz (separación entre las dos señales).

Tip: para calcular $N_{\min}$, ponga $\Delta\omega/(2\pi) \cdot f_s < 50$ y despeje N .

Ejercicio 5: Periodograma, Bartlett y Welch

En las clases vimos tres métodos no paramétricos para estimar la densidad espectral de potencia (PSD) de una señal:

Periodograma: $\hat{P}(e^{j\omega}) = \frac{1}{N} |X_N(e^{j\omega})|^2$. Es la DFT al cuadrado, normalizada.

Bartlett: parte la señal en K bloques de longitud L sin solapar, calcula el periodograma de cada uno, y los promedia.

Welch: igual que Bartlett pero los bloques sí se solapan (típicamente 50%) y cada bloque se envientana antes de hacer la FFT.

a) ¿Por qué el periodograma “no es un buen estimador”? Pista: pensar en sesgo y varianza, ¿mejoran al aumentar N ?

b) ¿Por qué Bartlett reduce la varianza? ¿Qué sacrifica para lograrlo?

c) ¿Por qué Welch es mejor que Bartlett? Mencione las dos mejoras que introduce.

d) (Tipo parcial) Tengo $N = 1000$ muestras de una señal aleatoria. Quiero estimar la PSD con baja varianza, pero también quiero resolución espectral aceptable. Decida una estrategia razonable: ¿cuántos bloques uso? ¿de qué tamaño? ¿qué ventana? Justifique.

Ejercicio 6: A jugar con La440.wav

Se proveen los archivos `La440.wav` y `La440_delay.wav`. La idea es que pruebe distintas ventanas con señales reales y vea cómo cambia el espectro.

a) Cargue `La440.wav` y gráfiquelo en el dominio del tiempo y en frecuencia (con ventana rectangular). ¿Aparece el pico esperado en 440 Hz? ¿Aparecen armónicos?

b) Habilite en el código las cinco ventanas (Rectangular, Hann, Hamming, Blackman-Harris y Flattop) descomentando las líneas correspondientes. Para cada una observe:

- ¿Cuál le da el pico más estrecho?
- ¿Cuál le da la amplitud más estable (más cerca de un valor “redondo”)?
- ¿Cuál deja la base del espectro más “limpia” (sin patas grandes)?

c) Simule una segunda señal cercana sumando al audio una senoidal de la misma amplitud pero a 450 Hz. ¿Se pueden distinguir las dos componentes con cada ventana? ¿Y si pone la segunda a 600 Hz?

d) Repita el análisis con `La440_delay.wav`. ¿Se nota la diferencia mirando el módulo del espectro? ¿Por qué?

Listing 2: NotaMusical_ventanas.py

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.io import wavfile
4 import scipy.signal.windows as spsw
5
6 # --- Leer WAV ---
7 fs, data = wavfile.read("La440.wav")
8
9 # A mono si viene estereo
10 if data.ndim == 2:
11     data = data.mean(axis=1)
12
13 # A float y quitar DC
14 x = data.astype(np.float64)
15 x = x - x.mean()
16
17 N = len(x)
18 Ts = 1.0 / fs
19
20 # --- Ventanas ---
21 ventanas = {
22     # "Rectangular": np.ones(N),
23     "Hann": spsw.hann(N, sym=False),
24     # "Hamming": spsw.hamming(N, sym=False),
25     # "Blackman-Harris": spsw.blackmanharris(N, sym=False),
26     # "Flattop": spsw.flattop(N, sym=False),
27 }
28
29 # --- Eje de frecuencias (unilateral) ---
30 freqs = np.fft.rfftfreq(N, d=Ts)
31
```

```

32 # --- Graficar las ventanas en el tiempo ---
33 tt = np.arange(N) * Ts
34 plt.figure(figsize=(9,4))
35 for nombre, w in ventanas.items():
36     plt.plot(tt, w, label=nombre, linewidth=1)
37 plt.xlabel("Tiempo [s]")
38 plt.ylabel("w[n]")
39 plt.title("Ventanas en el dominio del tiempo")
40 plt.grid(True)
41 plt.legend()
42 plt.tight_layout()
43
44 # --- FFT por ventana (con correccion CG) y graficos separados ---
45 for nombre, w in ventanas.items():
46     # Coherent Gain (ganancia a una senoidal "bin-centered")
47     CG = w.mean() # = sum(w)/N
48
49     xw = x * w
50     X = np.fft.rfft(xw) / (N * CG) # corregimos por N y CG para comparar
        amplitudes
51     mag = np.abs(X)
52
53     f0_est = freqs[np.argmax(mag)]
54
55     plt.figure(figsize=(9,4))
56     plt.plot(freqs, mag, label=f"{nombre} (pico ~ {f0_est:.2f} Hz)")
57     plt.xlim(0, 1000) # enfocamos cerca de 440 Hz; cambia si quieres ver
        mas
58     plt.xlabel("Frecuencia [Hz]")
59     plt.ylabel("|X(f)| (u.a.)")
60     plt.title(f"Espectro con ventana {nombre}")
61     plt.grid(True)
62     plt.legend()
63     plt.tight_layout()
64
65 # --- (Opcional) Respuesta en frecuencia de las ventanas ---
66 # Muestra lobulos laterales y ancho del lobulo principal (normalizado a 0
    dB en DC)
67 zp = 16 * N # zero-padding para ver bien la forma
68 freqs_win = np.fft.rfftfreq(zp, d=Ts)
69 plt.figure(figsize=(9,5))
70 for nombre, w in ventanas.items():
71     W = np.fft.rfft(w, n=zp)
72     # Normalizamos a 0 dB en DC (|W[0]| = sum(w))
73     W_db = 20*np.log10(np.maximum(np.abs(W) / (np.abs(W[0]) + 1e-12), 1e
        -12))
74     plt.plot(freqs_win, W_db, label=nombre, linewidth=1)
75 plt.xlim(0, 2000) # para comparar alrededor de 0-2 kHz
76 plt.ylim(-120, 3)
77 plt.xlabel("Frecuencia [Hz]")
78 plt.ylabel("|W(f)| [dB] (normalizado a 0 dB)")
79 plt.title("Respuesta en frecuencia de las ventanas (dB)")
80 plt.grid(True, which="both", axis="both")
81 plt.legend()
82 plt.tight_layout()
83
84 plt.show()

```