

Guía G5

Ventanas para Análisis Espectral

Ideas clave

Holton, Cap. 14

Toda señal analizada con la DFT es de **duración finita**: equivale a multiplicar la señal original por una **ventana** $w_N[n]$:

$$\hat{x}[n] = x[n] \cdot w_N[n] \implies \hat{X}(\omega) = \frac{1}{2\pi} X(\omega) * W_N(\omega)$$

El espectro resultante es la *convolución* entre el espectro verdadero y la transformada de la ventana, lo que introduce dos efectos adversos:

- **Desparramo** (*spectral spread*): el ancho del lóbulo principal de $W_N(\omega)$ limita la *resolución espectral*, es decir, la capacidad de separar dos componentes próximas en frecuencia.
- **Filtración** (*spectral leakage*): los lóbulos laterales de $W_N(\omega)$ crean un “piso espectral” que puede enmascarar componentes de pequeña amplitud alejadas de la componente dominante.

Parámetros clave de una ventana (Holton, Sec. 14.1.2):

Ventana	$\Delta\omega$ (lób. principal)	$\Delta A_{\max}$	Decaída	Punto fuerte
Rectangular	$4\pi/N$	-13 dB	-6 dB/oct	Máxima resolución
Hann	$8\pi/N$	-32 dB	-18 dB/oct	Compromiso general
Hamming	$8\pi/N$	-43 dB	-6 dB/oct	Primer lóbulo mín.
Blackman-Harris	$12\pi/N$	-92 dB	—	Señales muy débiles
Flatop	$\approx 18\pi/N$	-93 dB	—	Medición de amplitud

Periodicidad Implícita y Desparramo Espectral

Ejercicio 1. Responda las siguientes preguntas sobre los fundamentos del análisis espectral con DFT.

- Periodicidad implícita.** La DFT asume que la señal analizada se repite periódicamente. Explique, en sus propias palabras, por qué esta suposición introduce *discontinuidades artificiales* cuando la frecuencia de la señal no corresponde exactamente a un bin de la DFT. Ayuda: piense qué ocurre al “pegar” el último y el primer valor del bloque analizado.
- Spread vs. leakage.** Holton (Sec. 14.1.3) distingue dos efectos adversos del enventanado. Explique la diferencia entre *spectral spread* y *spectral leakage*:
 - ¿Cuál de los dos limita la resolución entre dos tonos cercanos?
 - ¿Cuál de los dos impide detectar una componente débil cerca de una fuerte?
 - ¿De qué parámetro de la ventana depende cada uno?
- Ejemplo numérico.** Se tiene $x[n] = \cos(2\pi \cdot 205 \cdot n/f_s)$ con $f_s = 1000$ Hz y se analizan $N = 100$ muestras.
 - Calcule el espaciado de bins: $\Delta f = f_s/N$.

- Determine si $f_0 = 205 \text{ Hz}$ cae exactamente en un bin. Exprese el desvío en fracción de bin ($\Delta \in [-0.5, 0.5]$).
- Si se usara una ventana rectangular, ¿en qué región del espectro aparecería energía que no pertenece a f_0 ? Describa cualitativamente usando los conceptos de spread y leakage.

Propiedades y Elección de Ventanas

Ejercicio 2. Utilice la tabla de la caja de ideas clave (Holton, Fig. 14.6) para responder.

a) **Resolución mínima.** La resolución espectral en Hz puede estimarse como:

$$\Delta f_{\min} = \frac{\Delta\omega}{2\pi} \cdot f_s$$

donde $\Delta\omega$ es el ancho del lóbulo principal de la ventana. Para $f_s = 8000 \text{ Hz}$ y $N = 800$ muestras, calcule $\Delta f_{\min}$ para cada una de las cinco ventanas de la tabla. ¿Cuál permite separar dos tonos a 50 Hz de distancia?

- b) **Piso de leakage.** Suponga una señal formada por dos sinusoidales: la primera de 0 dB y la segunda de -40 dB, separadas 50 Hz. Para cada ventana, indique si los lóbulos laterales de la señal dominante (0 dB) *enmascaran* o *no enmascaran* la señal débil (-40 dB). Use directamente el valor $\Delta A_{\max}$ de la tabla.
- c) **Ventana Flatop.** La ventana Flatop tiene el lóbulo principal más ancho de la tabla. Sin embargo, la comunidad de metrología la usa ampliamente. ¿Para qué aplicación resulta útil? ¿Qué propiedad del lóbulo principal justifica su uso?
- d) **Decaída de lóbulos laterales.** La columna “decaída” indica cuán rápido caen los lóbulos laterales a medida que nos alejamos de la frecuencia de la señal. Compare Hamming (-6 dB/oct) vs. Hann (-18 dB/oct): ambas tienen el mismo $\Delta A_{\max}$ del primer lóbulo lateral, pero se comportan diferente a frecuencias distantes. ¿Cuál conviene si la señal débil está *lejos* en frecuencia de la dominante?

Sego en Estimación de Amplitud: Ventana Rectangular vs. Flatop

Ganancia coherente (CG) y corrección de amplitud

Holton, Sec. 14.1.2

Dado un espectro ventaneado $X_w[k] = \text{FFT}\{x[n] \cdot w[n]\}$, el pico espectral en la frecuencia de una senoide de amplitud A vale, aproximadamente:

$$|X_w[k_0]| = \frac{N}{2} \cdot \text{CG} \cdot A \cdot |\text{sinc}(\Delta)|$$

donde la **ganancia coherente** $\text{CG} = \frac{1}{N} \sum_{n=0}^{N-1} w[n]$ y $\Delta \in [-0.5, 0.5]$ es el desvío en fracción de bin entre f_0 y el bin más cercano.

Para recuperar la amplitud verdadera A se aplica la corrección:

$$\hat{A} = \frac{2|X_w[k_0]|}{N \cdot \text{CG}}$$

Esta corrección *solo es exacta si* $\Delta = 0$ (la frecuencia cae en un bin exacto) o si la ventana tiene lóbulo principal *plano* (Flatop).

Ejercicio 3. Sea $x[n] = A \cdot \sin(\Omega_1 \cdot n)$ con $A = 2$, $\Omega_0 = \pi/2$ y $\Omega_1 = \Omega_0 + \Delta \cdot \frac{2\pi}{N}$, donde Δ es un desvío fraccional ($\Delta = 0$: frecuencia exactamente en bin; $\Delta = 0.5$: exactamente a mitad entre dos bins).

- a) **Ventana rectangular**, $\Delta = 0$. Calcule el valor teórico de $|X_w[k_0]|$ para la ventana rectangular ($CG_{\text{rect}} = 1$) y $N = 1000$. Verifique que la corrección $\hat{A} = 2|X_w|/(N \cdot CG)$ recupera $A = 2$.
- b) **Ventana rectangular**, $\Delta = 0.5$. Cuando la frecuencia cae a mitad de bin, el factor de atenuación es:

$$|\text{sinc}(\Delta)| = \left| \frac{\sin(\pi\Delta)}{\pi\Delta} \right| \bigg|_{\Delta=0.5} = \frac{2}{\pi} \approx 0.637$$

¿Qué amplitud $\hat{A}$ estima la ventana rectangular? Expresé el error en dB. ¿Es un error de *sesgo* o de *varianza*? ¿Por qué?

- c) **Ventana Flatop**. La ventana Flatop se diseña para que $|\text{sinc}(\Delta)| \approx 1$ para cualquier $|\Delta| \leq 0.5$. Explique *cualitativamente* (sin calcular) cómo logra esto: ¿cómo debe ser la forma de su lóbulo principal en frecuencia? ¿Qué sacrifica para lograrlo?
- d) **Conexión con la TS4**. En la TS4 se estudia el estimador de amplitud $\hat{a}_1 = |X_w^i(\Omega_0)|$ para distintas ventanas con $\Omega_1 = \Omega_0 + f_r \cdot \frac{2\pi}{N}$, donde $f_r \sim \mathcal{U}(-2, 2)$.
- ¿Qué ventana producirá menor *sesgo* en la estimación de amplitud?
 - ¿Qué ventana producirá menor *varianza* en la estimación de frecuencia?
 - ¿Son las mismas? ¿Qué trade-off refleja esto?

Ejercicio Integrador: Dos Señales Próximas

Contexto: Un escenario típico en instrumentación es la presencia de dos sinusoidales con muy distinta amplitud y frecuencias próximas, sumergidas en ruido. La elección de ventana, N y f_s determina si podemos *resolver* ambas componentes y detectar la más débil sin que la más fuerte la enmascare. Este tipo de problema aparece en los parciales de la materia.

Ejercicio 4. Se tiene una señal:

$$x(t) = \underbrace{A_1 \cos(2\pi f_1 t)}_{0 \text{ dB}, f_1=1000 \text{ Hz}} + \underbrace{A_2 \cos(2\pi f_2 t)}_{-40 \text{ dB}, f_2=1050 \text{ Hz}} + n(t)$$

donde el ruido $n(t)$ es gaussiano con nivel de piso -60 dB. El sistema de adquisición trabaja a $f_s = 8000$ Hz.

- a) **Condición de resolución.** La separación entre f_1 y f_2 es $\Delta f = 50$ Hz. Para cada ventana de la tabla del Ejercicio 2, determine el N mínimo tal que $\Delta f_{\min} < \Delta f$. Organice los resultados en una tabla de dos columnas: ventana y $N_{\min}$.

- b) **Condición de leakage.** Independientemente de N , analice si cada ventana puede “ver” A_2 por encima del piso de lóbulos laterales de A_1 (que está 40 dB por encima). Use la columna $\Delta A_{\max}$ directamente. Indique para cada ventana: ¿resuelve? ¿detecta A_2 ?
- c) **Ventana óptima.** Seleccione la ventana que satisfaga *ambas* condiciones (resolución y detección de A_2) con el menor N posible. Proponga un valor de N práctico (potencia de 2, mayor que $N_{\min}$) y calcule la resolución efectiva $\Delta f = f_s/N$ que obtendría.
- d) **Pregunta conceptual de parcial.** Suponga ahora que el nivel de ruido sube de -60 dB a -30 dB. ¿Alcanza con cambiar la ventana? ¿Qué otras alternativas (relacionadas con N o con el método de estimación) podría explorar? Mencione al menos dos estrategias y cómo afectan sesgo y varianza del estimador.

Python: Análisis de Nota Musical

Ejercicio 5. (Exploratorio con código)

Se proveen los archivos `La440.wav` (nota La a 440 Hz) y `La440_delay.wav` (misma nota con retardo). Usando el código de la sección siguiente como base:

- a) **Respuesta en frecuencia de las ventanas.** Habilite las cinco ventanas del código (descomentando las líneas correspondientes) y grafique $|W_N(\omega)|_{\text{dB}}$ superpuestas. Identifique visualmente el ancho del lóbulo principal y el nivel del primer lóbulo lateral para cada una. Compare con la tabla teórica.
- b) **Estimación de frecuencia fundamental.** Para cada ventana, el código imprime la frecuencia del pico. ¿Todas coinciden en ≈ 440 Hz? ¿Cuál tiene mayor dispersión visualmente en el espectro alrededor del pico?
- c) **Estimación de amplitud con corrección CG.** El código ya aplica la corrección $X/(N \cdot \text{CG})$. Compare la amplitud estimada del pico entre ventanas. ¿Cuál da el valor más estable frente al hecho de que 440 Hz puede *no* caer exactamente en un bin según el N disponible? Ayuda: calcule el desvío Δ para la f_s y N del archivo.
- d) **(Opcional) Comparación con `La440_delay.wav`.** Cargue ambos archivos y superponga sus espectros (módulo) usando la misma ventana. ¿Se puede distinguir el retardo a partir del espectro de módulo? ¿Qué información del espectro sí reflejaría el retardo?

Código Python: Análisis con Ventanas

Para el Ejercicio 5: el parámetro `sym=False` genera una ventana *periódica* (apropiada para análisis espectral); `sym=True` genera una ventana *simétrica* (usada en diseño de filtros FIR). No los intercambie.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.io import wavfile
4 import scipy.signal.windows as spsw
5
6 # ===== Leer WAV =====
7 fs, data = wavfile.read("La440.wav")
8 if data.ndim == 2:          # stereo -> mono
9     data = data.mean(axis=1)
10 x = data.astype(np.float64)
11 x = x - x.mean()           # quitar componente DC
12
13 N = len(x)
14 Ts = 1.0 / fs
15
16 # ===== Definicion de ventanas (sym=False: periodica) =====
17 ventanas = {
18     "Rectangular":      np.ones(N),
19     "Hann":              spsw.hann(N, sym=False),
20     "Hamming":          spsw.hamming(N, sym=False),
21     "Blackman-Harris":  spsw.blackmanharris(N, sym=False),
22     "Flattop":          spsw.flattop(N, sym=False),
23 }
24
25 # ===== Eje de frecuencias unilateral =====
26 freqs = np.fft.rfftfreq(N, d=Ts)   # [0, fs/2] en Hz
27
28 # ===== Respuesta en frecuencia de las ventanas (zero-padding) =====
29 zp = 16 * N
30 freqs_win = np.fft.rfftfreq(zp, d=Ts)
31
32 plt.figure(figsize=(10, 5))
33 for nombre, w in ventanas.items():
34     W = np.fft.rfft(w, n=zp)
35     W_db = 20 * np.log10(np.abs(W) / (np.abs(W[0]) + 1e-14))
36     plt.plot(freqs_win, W_db, label=nombre, lw=1.2)
37
38 plt.xlim(0, 1500)
39 plt.ylim(-120, 3)
40 plt.xlabel("Frecuencia [Hz]")
41 plt.ylabel("|W(f)| [dB] (normalizado a 0 dB)")
42 plt.title("Respuesta en frecuencia de las ventanas")
43 plt.grid(True, which="both")
44 plt.legend()
45 plt.tight_layout()
46
47 # ===== Espectros con correccion CG =====
48 for nombre, w in ventanas.items():
49     CG = w.mean()                # Coherent Gain = (1/N) * sum(w)
50     xw = x * w
51     X = np.fft.rfft(xw) / (N * CG) # correccion de amplitud
52     mag = np.abs(X)
53
54     f0_est = freqs[np.argmax(mag)]
55

```

```

56 plt.figure(figsize=(9, 4))
57 plt.plot(freqs, mag, lw=1, label=f"{nombre} | pico ~ {f0_est:.2f} Hz")
58 plt.xlim(0, 1000)
59 plt.xlabel("Frecuencia [Hz]")
60 plt.ylabel("|X(f)| corregido (u.a.)")
61 plt.title(f"Espectro con ventana {nombre}")
62 plt.grid(True)
63 plt.legend()
64 plt.tight_layout()
65
66 # ===== ENBW: Equivalent Noise Bandwidth (en bins) =====
67 print(f"\n{'Ventana':<20} {'CG':>8} {'ENBW (bins)':>14}")
68 print("-" * 44)
69 for nombre, w in ventanas.items():
70     CG = w.mean()
71     ENBW = N * np.sum(w**2) / np.sum(w)**2
72     print(f"{nombre:<20} {CG:>8.4f} {ENBW:>14.4f}")
73
74 plt.show()

```

Listing 1: ventanas_analisis.py

Interpretación del ENBW: El **Equivalent Noise Bandwidth** (en bins) indica cuántos bins de la DFT “ve” efectivamente la ventana al estimar la potencia de ruido. Un ENBW mayor implica que la estimación de potencia incluye más ruido, lo que aumenta la varianza del estimador. Para la ventana rectangular, $\text{ENBW} = 1$ bin; para Hann, $\text{ENBW} \approx 1.5$ bins. El ENBW en Hz se obtiene como $\text{ENBW}_{\text{Hz}} = \text{ENBW}_{\text{bins}} \cdot (f_s/N)$.